



Wine Quality

BASE DE DADOS DE VINHOS





COMPREENSÃO DO PROBLEMA

Prevendo Qualidade com Ciência

- Avaliação tradicional de vinhos é subjetiva e dependente de especialistas
- Proposta: substituir análise sensorial por dados físico-químicos via Machine Learning
- Dataset: Wine Quality Dataset (Kaggle) — 1.143 amostras, 11 variáveis

Classificação binária definida como variável alvo:

- ● Alta Qualidade $\rightarrow$ nota ≥ 7
- ● Baixa/Média Qualidade $\rightarrow$ nota < 7

A person is operating a yellow agricultural machine, likely a harrow or similar, in a vast vineyard. The rows of grapevines stretch far into the distance, creating a strong sense of perspective. The scene is captured during the "golden hour" of sunset, with a warm, orange-brown light bathing the entire landscape. The person on the machine is wearing a light-colored shirt and dark pants, and is looking towards the camera. The machine has a platform with railings and some equipment on it.

ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

O que os dados revelam antes da modelagem

- 86% das amostras são Baixa/Média Qualidade × 14% Alta Qualidade
- Álcool é o maior preditor positivo de qualidade (+0.476)
- Acidez volátil é o maior preditor negativo (-0.391)
- Sulfatos apresentam contribuição positiva consistente (+0.251)
- Alta multicolinearidade identificada entre SO_2 livre e SO_2 total
- Outliers detectados com três métodos: IQR, Z-Score e Isolation Forest

PRÉ-PROCESSAMENTO DE DADOS

Limpeza e outliers

- Nenhum valor nulo encontrado no dataset
- Coluna Id removida por não ter valor preditivo
- Outliers com consenso entre os 3 métodos removidos (~81 registros, ~7%)

Feature Engineering

- `alcohol_acid_ratio` → razão álcool ÷ acidez volátil
- `free_so2_ratio` → proporção SO_2 livre ÷ SO_2 total
- `high_alcohol` → flag binária para álcool > 11%

Padronização

- Padronização com `StandardScaler` aplicada apenas no treino (split 80/20)
- SMOTE aplicado exclusivamente no treino para evitar data leakage

DESENVOLVIMENTO DE MODELOS

Modelos treinados

- Decision Tree — critério entropy, profundidade máxima 3
- Random Forest — otimizado via GridSearchCV com validação cruzada de 5 folds
- KNN — melhor valor de K definido por validação cruzada
- Regressão Logística — modelo baseline linear

Estratégia de balanceamento

- class_weight = balanced aplicado em todos os modelos
- SMOTE aplicado exclusivamente no treino — sem data leakage
- Treino expandido de 849 para 1.462 amostras sintéticas

AValiação dos Modelos

Modelo 1 — Decision Tree & Modelo 2 — Random Forest:

- Decision Tree (Sem SMOTE) → Recall 0.24 · Precisão 0.54 · F1 0.33 · Acurácia 86,85% · AUC-ROC 0.86
- Decision Tree (Com SMOTE) → Recall 0.83 · Precisão 0.39 · F1 0.53 · Acurácia 80,28% · AUC-ROC 0.84
- Random Forest (Sem SMOTE) → Recall 0.69 · Precisão 0.67 · F1 0.68 · Acurácia 91,08% · AUC-ROC 0.95
- Random Forest (Com SMOTE) → Recall 0.90 · Precisão 0.50 · F1 0.64 · Acurácia 86,38% · AUC-ROC 0.95

Modelo 3 — KNN & Modelo 4 — Regressão Logística:

- KNN (Sem SMOTE) → Recall 0.48 · Precisão 0.82 · F1 0.61 · Acurácia 91,55% · AUC-ROC 0.88
- KNN (Com SMOTE) → Recall 0.76 · Precisão 0.45 · F1 0.56 · Acurácia 84,04% · AUC-ROC 0.89
- Regressão Logística (Sem SMOTE) → Recall 0.90 · Precisão 0.46 · F1 0.60 · Acurácia 84,04% · AUC-ROC 0.93
- Regressão Logística (Com SMOTE) → Recall 0.86 · Precisão 0.43 · F1 0.57 · Acurácia 82,63% · AUC-ROC 0.92

INTERPRETAÇÃO DOS RESULTADOS

Variáveis mais Influentes:

- Álcool → 18,3% de importância, preditor isolado mais forte
- Sulfatos → 13,5%, segundo maior preditor positivo
- Razão álcool/acidez → 13,4%, valida o feature engineering
- Acidez volátil → 6,4%, principal preditor negativo, indica deterioração

Implicações para o Produtor:

- Monitorar fermentação para maximizar teor alcoólico acima de 11%
- Controle microbiológico rigoroso mantém acidez volátil em níveis seguros
- Ajuste de dosagem de SO_2 ao longo do envelhecimento melhora estabilidade
- Modelo pode atuar como sistema de alerta precoce antes do engarrafamento



OBRIGADO